

Analyse de données : performances et profils nationaux en natation olympique

Maxim Vicente
Base d'analyse de données
2025-2026

Introduction

Ce projet analyse les résultats olympiques de natation entre 1912 et 2020. Le jeu de données contient notamment l'année, l'épreuve, le sexe, le pays, le rang, les médailles et le temps réalisé. L'objectif est de transformer ces résultats bruts en une analyse statistique cohérente permettant de répondre à la problématique suivante :

Comment les performances en natation olympique ont-elles évolué entre 1912 et 2020, et quels profils de pays structurent cette évolution historique ?

L'analyse suit trois axes. On étudie d'abord l'évolution temporelle des performances, puis la structuration des nations en différents profils selon leur présence, leur régularité et leurs résultats, avant de proposer une projection des performances futures. Les méthodes utilisées sont celles vues en cours et en travaux pratiques : analyse descriptive, ACP, classification hiérarchique ascendante, K-means, méthode du coude, score de silhouette et régression linéaire.

1 Préparation des données

La première étape consiste à rendre les données exploitables. La variable la plus sensible est le temps, car les résultats sont écrits sous plusieurs formats : secondes simples, minutes :secondes, heures :minutes :secondes, ou encore valeurs numériques parfois exprimées en millisecondes. J'ai donc implémenté une fonction Python, `convert_time_to_seconds`, appliquée à la variable `Results` afin de convertir tous les temps en secondes. Les valeurs non exploitables, comme les abandons, disqualifications ou absences au départ, ont ensuite été supprimées afin de travailler uniquement sur des observations comparables.

Il faut également préciser que le fichier représente les performances disponibles dans le jeu de données, sans distinction systématique entre finales, séries ou demi-finales. Les analyses portent donc sur les observations exploitables du dataset, et non sur une base parfaitement exhaustive de toutes les performances olympiques.

Un second nettoyage concerne les pays. Certaines équipes apparaissent sous plusieurs codes selon les périodes historiques ou les conventions du jeu de données. Ainsi, les codes liés à l'Allemagne ont été regroupés sous `Germany`, ceux liés à la Russie et à l'URSS sous `Russia/USSR`, et les deux codes des Pays-Bas sous `Netherlands`. Cette harmonisation évite de fragmenter artificiellement une même continuité sportive. Enfin, les pays présents dans beaucoup d'épreuves et sur beaucoup d'éditions sont naturellement plus visibles, ce qui justifie l'utilisation à la fois d'indicateurs bruts et d'indicateurs relatifs.

2 Évolution temporelle des performances

Une première analyse globale montre que les temps moyens diminuent au cours du temps, ce qui traduit une amélioration générale des performances olympiques. Toutefois, cette lecture globale est limitée : elle mélange des distances, des nages et des sexes différents. L'analyse a donc été affinée sur cinq épreuves représentatives : le 100 m nage libre, le 100 m dos, le 200 m papillon, le 200 m brasse et le 400 m nage libre. Ces épreuves ont été retenues car elles couvrent plusieurs distances et plusieurs styles de nage, tout en disposant de séries temporelles suffisamment longues.




FIGURE 1 – Évolution des temps moyens pour plusieurs épreuves olympiques.

La figure 1 montre une baisse nette des temps dans plusieurs épreuves. Les progrès sont importants sur le long terme, mais ils ne sont pas parfaitement linéaires. Dans les périodes récentes, la baisse semble souvent plus lente, ce qui suggère un rapprochement progressif de limites physiques et techniques. Cette évolution peut aussi être liée à l'amélioration de l'entraînement, de la préparation physique, du matériel, de la professionnalisation du sport et des méthodes de sélection.

L'écart entre hommes et femmes a également été étudié. Plutôt que de comparer seulement des écarts en secondes, on utilise un écart relatif, plus pertinent pour comparer des épreuves de distances différentes :

$$\text{Écart relatif} = \frac{T_{\text{femmes}} - T_{\text{hommes}}}{T_{\text{hommes}}} \times 100.$$




FIGURE 2 – Évolution de l'écart relatif entre performances masculines et féminines.

Cette analyse montre que l'écart relatif tend à diminuer dans certaines épreuves, sans disparaître. Cela peut s'expliquer par l'amélioration de l'accès des femmes au sport de haut niveau, la professionnalisation et les progrès dans l'entraînement. Les dynamiques ne sont toutefois pas identiques selon les épreuves, ce qui justifie une analyse séparée par distance et par nage.

3 Profils de pays en natation olympique

La deuxième partie cherche à savoir si cette évolution est portée de manière homogène par l'ensemble des pays ou seulement par quelques nations dominantes. Pour cela, un tableau agrégé par pays a été construit. Les variables retenues décrivent le volume historique, la régularité, la diversité et l'efficacité relative : **Participations**, **Medals**, **Avg_rank**, **Years_present**, **Events_count**, **Medal_rate**, **Gold_rate** et **Medals_per_year**.

Les variables brutes montrent une très forte domination des États-Unis. Cependant, les indicateurs relatifs nuancent cette lecture : certains pays peu présents peuvent obtenir de bons taux, même si ces ratios doivent être interprétés avec prudence lorsque les effectifs sont faibles.




FIGURE 3 – Comparaison entre le classement des pays par volume total de médailles et par taux de médailles.

Les distributions des variables et la matrice de corrélation montrent que plusieurs variables sont très liées, en particulier les variables de médailles. Une ACP est donc utilisée afin de synthétiser l'information. Les données sont standardisées avant l'ACP, car les variables n'ont pas la même échelle. Si X désigne le tableau pays-variables, on travaille sur une version centrée-réduite X_{cr} , puis l'ACP revient à diagonaliser une matrice de corrélation :

$$R = X_{cr}^{\top} D X_{cr},$$

où D représente les poids des individus. L'objectif est de projeter les pays sur quelques axes factoriels résumant l'essentiel de l'information, tout en conservant une interprétation statistique des proximités entre pays.



FIGURE 4 – Projection des pays sur le plan factoriel de l'ACP.

Le premier axe de l'ACP correspond principalement à une dimension de domination globale : les pays situés à droite combinent beaucoup de participations, beaucoup de médailles et un fort rendement moyen. Les États-Unis apparaissent très isolés, ce qui confirme leur caractère atypique. Le deuxième axe apporte une nuance entre présence historique, diversité d'épreuves et efficacité relative. L'ACP permet donc de dépasser un simple classement par médailles et de faire apparaître des profils plus structurés, en distinguant le volume historique, la régularité et l'efficacité relative.

Pour formaliser ces profils, deux méthodes de clustering ont été appliquées : la classification hiérarchique ascendante et le K-means. La CAH permet d'observer progressivement les regroupements entre pays, tandis que K-means cherche directement une partition en K groupes en minimisant l'inertie intra-classe :

$$\sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2.$$




FIGURE 5 – Dendrogramme de la classification hiérarchique ascendante.

Le dendrogramme suggère une partition en quatre groupes. Ce choix est cohérent avec la méthode du coude et reste satisfaisant au regard du score de silhouette, tout en donnant une partition facilement interprétable. Graphiquement, le dendrogramme fait apparaître quatre grands regroupements avant les fusions les plus hautes, tandis que la méthode du coude montre qu'après $K = 4$, le gain d'inertie devient plus faible.




FIGURE 6 – Choix du nombre de clusters pour K-means : méthode du coude et score de silhouette.




FIGURE 7 – Projection des clusters K-means sur le plan de l'ACP.

Les deux méthodes convergent presque parfaitement. Elles identifient quatre profils : les États-Unis seuls, un groupe de grandes nations historiques, un groupe large de pays modestes ou intermédiaires, et un groupe de pays peu présents mais relativement efficaces. La comparaison entre CAH et K-means montre qu'un seul pays, le Danemark, change de groupe selon la méthode. Cette stabilité renforce la robustesse de la typologie obtenue.

4 Projection future des performances

La dernière partie utilise la régression linéaire pour projeter l'évolution future des temps moyens. Pour chaque épreuve, on ajuste un modèle de la forme :

$$T_i = \beta_0 + \beta_1 \text{Année}_i + \varepsilon_i.$$

Un premier modèle est ajusté sur l'ensemble de la période 1912-2020. Il capture la tendance historique générale, mais peut surestimer les progrès futurs car les améliorations ont été très fortes au début du XX^e siècle. Un second modèle est donc ajusté uniquement sur la période récente, à partir de 1980. Ce second choix revient à supposer une évolution localement linéaire, plus adaptée au ralentissement observé récemment.




FIGURE 8 – Comparaison des projections par régression longue période et par régression récente.

La figure 8 montre que la régression récente donne des projections plus prudentes. Elle tient mieux compte du ralentissement des progrès observé dans les dernières décennies. La régression linéaire reste cependant un modèle simple : elle ne prend pas en compte les limites physiologiques, les changements de règlement, les innovations techniques ou les politiques sportives.

Afin de rendre ces projections plus concrètes, on peut comparer les prédictions obtenues pour 2024 avec les temps effectivement réalisés par les vainqueurs et vainqueuses en cette même année sur les épreuves étudiées. Cette comparaison permet surtout de vérifier les ordres de grandeur, sans considérer les prédictions comme des valeurs exactes. Elle rappelle aussi que le modèle prédit des temps moyens par épreuve, alors que les performances gagnantes correspondent à des résultats particuliers, dépendant du contexte de la course.

Year_pred	2024	2040	2050
Event			
100m Backstroke	54.765602	52.700625	51.410014
100m Freestyle	49.587489	48.040625	47.073835
200m Breaststroke	130.206651	124.393640	120.760509
400m Freestyle	232.644231	228.929943	226.608513

Moyenne des temps réalisés par le vainqueur homme et la vainqueuse femme pour chaque épreuve :

- 100 m dos : 54,67 s
- 100 m nage libre : 49,28 s
- 200 m brasse : 132,55 s
- 400 m nage libre : 229,64 s

(a) Prédiction du modèle récent

(b) Temps gagnants observés en 2024

FIGURE 9 – Comparaison entre les projections du modèle récent et les temps gagnants observés en 2024.

La figure 9 montre que les projections sont du même ordre de grandeur que les performances observées en 2024. Les écarts restent cependant normaux, car le modèle prédit des temps moyens et non les résultats exacts d'une finale olympique.

Conclusion

L'analyse permet de répondre à la problématique initiale. D'abord, les performances en natation olympique s'améliorent nettement sur le long terme, même si cette amélioration ralentit dans la période récente. Ensuite, les pays ne se distinguent pas seulement par leur total de médailles : les méthodes multivariées font apparaître de vrais profils nationaux. Les États-Unis constituent un cas exceptionnel, tandis qu'un groupe de grandes nations historiques se distingue par sa régularité et son volume de performances. Enfin, les projections futures sont possibles, mais elles doivent être interprétées avec prudence.

Ce projet montre donc que la natation olympique peut être lue comme une histoire double : une histoire temporelle de progression des performances, et une histoire géographique de domination et de spécialisation des nations. Les principales limites viennent de la structure du jeu de données, des effectifs très déséquilibrés entre pays, de l'absence de distinction systématique entre les types de courses, et du caractère simplificateur des modèles linéaires. Des prolongements possibles seraient d'intégrer les résultats complets de 2024, de séparer les analyses par période historique ou encore d'étudier plus finement l'effet des changements de règlement, des innovations techniques et des politiques sportives nationales.